

Rapport d'Architecture Stratégique

Fondations Cloud & Data Engineering : Azure & Databricks

Ce rapport présente l'architecture technique et les services Cloud et Big Data qui constitueront le socle du projet. L'objectif est de mettre en évidence la valeur stratégique de chaque composant et leur intégration dans une logique d'ingénierie de données robuste, évolutive et alignée sur les objectifs métiers.

■ 1. Azure SQL Database

Azure SQL Database est un service de base de données relationnelle entièrement géré (PaaS) fourni par Microsoft. Il repose sur le moteur SQL Server mais abstrait l'infrastructure sous-jacente pour permettre aux équipes de se concentrer sur l'optimisation des requêtes et la logique métier.

- **Définition** : Un système de gestion de bases de données relationnelles (SGBDR) en tant que service, offrant des capacités intégrées de haute disponibilité, de sauvegarde automatisée et de sécurité avancée.
- **Cas d'usage** : Idéal pour les charges de travail transactionnelles (OLTP), le stockage de données hautement structurées, ou pour agir comme une couche de présentation (Data Mart) optimisée pour les outils de Business Intelligence (Power BI, Tableau).
- **Avantages** : Scalabilité dynamique, zéro maintenance d'infrastructure, sécurité d'entreprise (chiffrement et intégration Microsoft Entra ID).

IMPACT STRATÉGIQUE (RÔLE DANS LE PROJET)

Azure SQL Database agira soit comme la source des données opérationnelles fiables, soit comme la destination finale (couche de présentation) hébergeant les données agrégées et prêtes à être consommées par les décideurs pour piloter l'activité.

▲ 2. Azure Data Lake Storage (ADLS Gen2)

ADLS Gen2 est la solution de stockage Cloud conçue spécifiquement pour les charges de travail d'analyse Big Data. Elle combine les capacités d'un système de fichiers hiérarchique avec le modèle de stockage d'objets d'Azure Blob Storage.

- **Fonctionnement & Hiérarchie** : Utilise un espace de noms hiérarchique (Account > Container > Directory > File) permettant des opérations sur les répertoires à l'échelle du pétaoctet avec des performances optimales.
- **Notion de Container** : Le regroupement logique de niveau supérieur agissant comme un point d'isolation pour gérer les politiques d'accès (RBAC, ACL) et compartimenter les données par environnement.



Figure 1 : Architecture Medallion au sein du Data Lake

Architecture Medallion : ADLS Gen2 est le fondement de cette conception stratégique garantissant la qualité des données à travers les couches Bronze (historisation brute sans altération), Silver (source de vérité nettoyée) et Gold (modélisée pour l'analyse métier).

► 3. Azure Data Factory (ADF)

Azure Data Factory est le chef d'orchestre de l'architecture. C'est un service d'intégration de données sans serveur permettant de créer, planifier et gérer des flux de données à grande échelle.




Figure 2 : Orchestration ELT via Azure Data Factory

- **Pipelines & Activités :** Regroupement logique planifiable. La *Copy Activity* déplace les données massivement sans altérer la logique métier.
- **Linked Services & Datasets :** Chaînes de connexion sécurisées aux sources de calcul/données, et vues référençant les données en entrée/sortie.

CAS D'USAGE ELT

ADF extraira les données sources pour les charger dans la couche Bronze (Extract & Load), puis orchestre les processus externes (Databricks) pour appliquer la logique métier (Transform), réduisant ainsi les goulots d'étranglement.

◆ 4. Databricks Community Edition

Databricks est une plateforme d'analyse unifiée basée sur Apache Spark. La Community Edition permet le prototypage et la validation des logiques de transformation complexes avant le passage en production.

- **Notebooks** : Interfaces web interactives pour écrire du code (Python, SQL), documenter et visualiser en temps réel.
- **Traitement distribué** : Le moteur Apache Spark divise et exécute les calculs en parallèle sur plusieurs nœuds, indispensable pour le Big Data.
- **Spark DataFrames** : Collections distribuées optimisées offrant une API riche pour transformer la donnée avec un haut niveau d'abstraction.

LOGIQUE MÉTIER & TRANSFORMATION

Databricks agira comme le moteur "cerveau" du projet : lecture de la couche Bronze, nettoyage intensif (Silver) et calculs d'agrégations complexes (Gold) propulsant la valeur analytique finale.